Interprétation et compilation

Chapitre 0

Introduction
Présentation du cours

Pablo Rauzy <pr@up8.edu>
pablo.rauzy.name/teaching/ic

Introduction

Une science du langage

- Il n'est pas déraisonnable de voir l'informatique comme une science des *langages*.

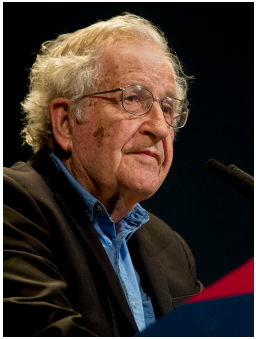

Noam Chomsky

Les langages sont des outils

- Les langages sont les outils de l'informaticien·ne.
- Différents problèmes se règlent avec différents outils.
- Abstraction ultime : créer son propre langage.

Interpréteur

- Un *interpréteur* est un programme qui prend en entrée un code source et exécute directement ses instructions.
- Les instructions sont interprétées dans le langage “hôte”.
- Le fonctionnement global d’un interpréteur est le cycle suivant :
  1. lire et analyser une expression ;
  2. si elle est valide (syntaxe, etc.), l’évaluer,
     sinon, rapporter une erreur ;
  3. passer à l’expression suivante.

Démo : mini interpréteur

- Démonstration d'un mini interpréteur "vite fait mal fait".
- Ajout d'une (ou deux) fonctionnalité(s).

Compilateur

- Un *compilateur* est un programme qui prend en entrée un code source et qui le traduit dans un autre langage, généralement de plus bas niveau.
- Le plus souvent le compilateur produit un fichier binaire exécutable, mais pas forcément.
- Le compilateur fait la traduction une fois pour toutes, contrairement à l'interpréteur.
- Un compilateur est *correct* si la *sémantique* du code produit est la même que celle du code source.

Démo : mini compilateur

- Démonstration d'un mini compilateur "vite fait mal fait".
- Ajout d'une (ou deux) fonctionnalité(s).

Structure globale d'un compilateur

- Idéalement, un compilateur est divisible en trois parties :
  - le *front end* (partie avant) est responsable de la lecture du code source et de sa transformation en *langage intermédiaire* ;
  - la *middle end* (partie centrale) est optionnelle, elle fait une ou plusieurs passes de traitement sur le langage intermédiaire (des optimisations par exemple) ;
  - le *back end* (partie finale) est responsable de produire le code final à partir du langage intermédiaire.

Structure globale d'un compilateur

- Idéalement, un compilateur est divisible en trois parties :
  - le *front end* (partie avant) est responsable de la lecture du code source et de sa transformation en *langage intermédiaire* ;
  - la *middle end* (partie centrale) est optionnelle, elle fait une ou plusieurs passes de traitement sur le langage intermédiaire (des optimisations par exemple) ;
  - le *back end* (partie finale) est responsable de produire le code final à partir du langage intermédiaire.

  Quel est l'avantage de cette architecture selon vous ?

Structure globale d'un compilateur

- Idéalement, un compilateur est divisible en trois parties :
  - le *front end* (partie avant) est responsable de la lecture du code source et de sa transformation en *langage intermédiaire* ;
  - la *middle end* (partie centrale) est optionnelle, elle fait une ou plusieurs passes de traitement sur le langage intermédiaire (des optimisations par exemple) ;
  - le *back end* (partie finale) est responsable de produire le code final à partir du langage intermédiaire.

  Quel est l'avantage de cette architecture selon vous ?
- Le code en langage intermédiaire n'a que rarement besoin d'être représenté textuellement, on manipule généralement des *arbres de syntaxe abstraite* (on parle d'AST, pour "abstract syntax tree").

Chaîne de compilation

- En fait, le compilateur à proprement parler n'est qu'une étape de la *chaîne de compilation*.
- Il y a parfois des outils qui passent avant le compilateur, par exemple :
  - un *préprocesseur* qui opère des transformations superficielles sur le code source,
  - un autre compilateur qui traduit d'un langage de haut niveau à un autre (par exemple vers le C).
- Selon le langage cible, il peut y avoir d'autres outils après le compilateur, par exemple :
  - un *assembleur* pour créer du code objet,
  - (puis) un *éditeur de lien* pour créer un exécutable,
  - une *machine virtuelle* dans le cas où le compilateur produit du "bytecode".

L'œuf ou la poule

- Comment a-t-on écrit le premier compilateur ?

- Comment a-t-on écrit le premier compilateur ?
- Historiquement, le premier compilateur est A-0, il a été écrit par Grace Hopper.
  Il s'agit plutôt d'un genre d'éditeur de lien, selon les standards actuels.

Grace Hopper

- Comment a-t-on écrit le premier compilateur ?
- Historiquement, le premier compilateur est A-0, il a été écrit par Grace Hopper.
  Il s'agit plutôt d'un genre d'éditeur de lien, selon les standards actuels.
- Aujourd'hui, le problème ne se pose plus vraiment, sauf pour le *bootstrapping* d'un compilateur, c'est à dire écrire le compilateur d'un langage dans ce langage.

- Quels sont selon vous les avantages du bootstrapping ?
- Pouvez-vous imaginer quelques méthodes de bootstrapping ?

- En 1984, Ken Thompson a reçu le prix Turing.
- Pendant son discours, il a présenté une idée intéressante à propos de la confiance qu'on peut avoir en un compilateur...
- `https://pablo.rauzy.name/dev/trustingtrust.pdf`

Interpréteurs et compilateurs

- Les liens entre interprétation et compilation sont assez étroits.

Langages interprétés et langages compilés

- On entend souvent parler de langages interprétés ou compilés,
  par exemple “python est un langage interprété, C est un langage compilé”.
- Il s’agit en fait d’un abus de langage.
- Il est théoriquement possible d’écrire des interpréteurs et des compilateurs pour tout type de langage.
- En pratique, il existe tout un spectre de techniques intermédiaires entre l’interprétation pure et la compilation pure, par exemple :
  - bytecode et machine virtuelle (VM),
  - compilation “just-in-time” (JIT),
  - et parfois même les deux en même temps !

Des parties communes dans le “front end”

- L’*analyse lexicale* découpe le texte du code source en une suite de *lexèmes*.
- L’*analyse syntaxique* structure le code en fonction d’une *grammaire formelle*.
- L’*analyse sémantique* vérifie la *validité* du code.

Ce qui diffère

- Comme on l'a déjà vu :
  - l'interpréteur évalue/exécute le code directement et *au fur et à mesure*,
  - le compilateur analyse d'abord l'entièreté du code source puis génère du code cible.

Présentation du cours

Aperçu

- En cours :
  - Détailler et approfondir tout ce qu'on a vu superficiellement aujourd'hui.
  - Écrire des interpréteurs et des compilateurs.
  - Utiliser les bons outils pour ça.
- En TP :
  - Mettre en pratique les notions du cours.
  - Apprendre à se servir des outils.
- Projet :
  - Écrire un compilateur d'un sous-ensemble de C vers de l'assembleur MIPS.
  - En utilisant le langage OCaml et le simulateur `spim`.

Plan du cours

- Approche “à l’envers”.
- Le cours va être composé de modules d’une ou deux semaines.
  1. Introduction OCaml.
  2. Assembleur MIPS.
  3. Génération de code.
  4. Compilation.
  5. Analyse sémantique.
  6. Analyse syntaxique.
  7. Analyse lexicale.
- Chaque module fera l’objet d’au moins un TP.

Évaluation

- Votre évaluation pour ce cours prendra en compte (dans l'ordre d'importance) :
  - le projet,
  - certains TPs,
  - un devoir sur table sur les parties théoriques du cours.
- La propreté du code (nommage, indentation, organisation) est importante est sera prise en compte autant pour les TP que pour le projet.